Universidad de Antioquia — Facultad de Ingeniería

Departamento de Ingeniería de Sistemas — Introducción al Aprendizaje Automático, 2026-2

Reconocimiento de actividades humanas a partir de los sensores inerciales de un *smartphone*

Primer informe de avance: descripción del problema y estado del arte

Juan David Villota Córdoba y Sammir Alejandro Bolaños Luna — Grupo 11

***Resumen*—El reconocimiento de actividades humanas (HAR, por sus siglas en inglés) busca identificar automáticamente qué hace una persona a partir de mediciones de sensores. Los teléfonos inteligentes incorporan acelerómetros y giroscopios, lo que permite hacerlo sin equipos adicionales. Este proyecto aborda el problema con la base de datos *Human Activity Recognition Using Smartphones* del repositorio UCI, que contiene 10 299 ventanas de señales inerciales de 30 voluntarios, descritas por 561 características y etiquetadas con seis actividades. Planteamos el problema como una clasificación supervisada multiclase y destacamos que la evaluación debe ser independiente del sujeto. En este primer informe se describe el problema, se analiza la composición de la base de datos y se revisan trabajos que la han utilizado.**

***Index Terms*—Reconocimiento de actividades humanas, sensores inerciales, *smartphone*, clasificación multiclase, aprendizaje automático.**

I. Descripción del problema

I-A. Contexto y utilidad de una solución basada en ML

Saber qué actividad realiza una persona (caminar, subir escaleras, estar sentada o acostada) es útil en el seguimiento de la actividad física, el cuidado de adultos mayores, la rehabilitación y las aplicaciones que se adaptan al contexto del usuario [2]. Hacerlo con cámaras o con sensores especializados es costoso e invasivo. En cambio, la mayoría de las personas ya lleva consigo un teléfono con acelerómetro y giroscopio.

El reto es que las señales inerciales no dicen directamente qué actividad ocurre. Son series de tiempo ruidosas que varían entre personas, y algunas actividades producen señales muy parecidas; por ejemplo, estar de pie y estar sentado son ambas posturas estáticas. Escribir reglas a mano para cada actividad es poco práctico. El aprendizaje automático permite aprender esas reglas a partir de ejemplos etiquetados, y la literatura reporta exactitudes cercanas o superiores al 95 % en esta misma base de datos [2], [3], [5].

I-B. Composición de la base de datos

La base de datos *Human Activity Recognition Using Smartphones* [1] fue presentada por Anguita *et al.* [2]. Treinta voluntarios de entre 19 y 48 años realizaron seis actividades llevando un Samsung Galaxy S II en la cintura. Se registraron la aceleración lineal y la velocidad angular en tres ejes a 50 Hz, y las sesiones se grabaron en video para etiquetar los datos manualmente.

Tabla I
Composición de la base de datos [1], [2].

Aspecto	Valor
Muestras	10 299 ventanas de 2.56 s
Características	561, numéricas continuas
Voluntarios	30 (19 a 48 años)
Clases	6 actividades
Partición oficial	70 % de los voluntarios para entrenamiento (7 352 ventanas) y 30 % para prueba (2 947) [2], [5]
Datos faltantes	Ninguno, según la ficha de UCI

Las señales se procesaron así [1]:

- Se filtró el ruido y se segmentaron en ventanas deslizantes de 2.56 s con 50 % de traslape, es decir, 128 lecturas por ventana.
- Con un filtro Butterworth pasa-bajas de 0.3 Hz se separó la aceleración total en una componente corporal y una gravitacional.
- De cada ventana se calcularon características en el dominio del tiempo y de la frecuencia.

El resultado es una tabla de 10 299 muestras (ventanas) y **561 características numéricas**. Cada muestra tiene dos datos adicionales: la etiqueta de actividad y el identificador del voluntario. La Tabla I resume la composición.

Significado de las variables. Los nombres de las 561 características siguen un patrón: *dominio* + *señal* + *estadístico* + *eje*. Por ejemplo, `tBodyAcc-mean()-X` es la media, en el dominio del tiempo, de la aceleración corporal en el eje X, y `fBodyGyro-std()-Z` es la desviación estándar del espectro de la velocidad angular en el eje Z. El prefijo `t` indica dominio del tiempo y `f`, dominio de la frecuencia, obtenido con la transformada rápida de Fourier. Los estadísticos incluyen media, desviación estándar, máximo, mínimo, energía, entropía, correlación entre ejes y coeficientes autorregresivos,

Profesor: Julián D. Arias-Londoño. Repositorio del proyecto: https://github.com/JUAN-VILLOTA/har-smartphones-ml-grupo11.

Tabla II
NÚMERO DE VENTANAS POR ACTIVIDAD.

Actividad	Entren.	Prueba	Total (%)
Caminar	1 226	496	1 722 (16.7)
Subir escaleras	1 073	471	1 544 (15.0)
Bajar escaleras	986	420	1 406 (13.7)
Sentado	1 286	491	1 777 (17.3)
De pie	1 374	532	1 906 (18.5)
Acostado	1 407	537	1 944 (18.9)
Total	7 352	2 947	10 299

entre otros.

Distribución de clases. La Tabla II presenta el número de ventanas por actividad.

Las clases están razonablemente balanceadas. La menos representada es *bajar escaleras* (13.7 %) y la más representada es *acostado* (18.9 %), una relación de 1.4 a 1. Por tanto, no planeamos usar técnicas de sobremuestreo ni submuestreo. Aun así, reportaremos métricas por clase, porque un desbalance leve puede ocultar fallos en una clase concreta.

Datos faltantes e imputación. La ficha de UCI indica que la base de datos no tiene valores faltantes [1]. El notebook del repositorio lo verifica: cuenta los valores vacíos de las 561 características y revisa su tipo de dato. Por tanto, no se requiere una estrategia de imputación.

Codificación de las variables. Las 561 características son numéricas y se usan directamente como entradas. Para los modelos sensibles a la escala, como SVM, k vecinos y redes neuronales, se estandarizan con parámetros calculados solo sobre el conjunto de entrenamiento. La etiqueta de actividad viene como un entero del 1 al 6. Como los números no tienen un orden con significado, se tratan como categorías: un identificador de clase para la mayoría de los clasificadores y codificación *one-hot* para la salida de la red neuronal. El identificador del voluntario **no** se usa como entrada, porque el modelo debe reconocer actividades de personas que no ha visto. Solo se usa para construir las particiones de validación.

La Fig. 1(b) muestra que, incluso con solo dos componentes principales, las actividades estáticas (*sentado*, *de pie* y *acostado*) se agrupan a la izquierda, separadas de las dinámicas (*caminar*, *subir* y *bajar escaleras*). Dentro de cada grupo, en cambio, las clases se superponen. En particular, *sentado* y *de pie* ocupan casi la misma región, lo que anticipa la confusión entre ambas reportada por Anguita *et al.* [2]. Esta proyección es solo exploratoria; la reducción de dimensión formal se abordará en una entrega posterior.

I-C. Paradigma de aprendizaje y justificación

El problema se aborda como **aprendizaje supervisado de clasificación multiclase**. Es supervisado porque cada ventana tiene una etiqueta de actividad obtenida a partir de video. Es de clasificación multiclase porque la salida es una de seis categorías. Formalmente, buscamos una función

$$f : \mathbb{R}^{561} \to \mathcal{C}, \qquad \hat{c} = f(\mathbf{x}), \tag{1}$$

donde $\mathcal{C}$ contiene las seis actividades (caminar, subir escaleras, bajar escaleras, sentado, de pie y acostado) y $\hat{c}$ es la actividad que el modelo asigna al vector de características $\mathbf{x}$ de una ventana.

Evaluación independiente del sujeto. Las ventanas de una misma persona se parecen mucho entre sí, y además dos ventanas consecutivas comparten el 50 % de sus lecturas. Si se dividen las ventanas al azar, el modelo vería en entrenamiento casi los mismos datos que luego se usan para evaluarlo, y la exactitud resultaría optimista. Por eso todas las particiones del proyecto se harán *por voluntario*: se respeta la partición oficial [2], y dentro del entrenamiento se usará validación cruzada agrupada por sujeto para ajustar hiperparámetros. Así medimos lo que importa en la práctica: el desempeño con personas nuevas.

Métricas previstas. Como hay seis clases, además de la exactitud reportaremos la matriz de confusión y el F1 macro. El F1 macro promedia el desempeño de todas las clases por igual y revela si el modelo falla en alguna en particular, como la confusión entre *sentado* y *de pie* que reportan los autores de la base de datos [2].

II. ESTADO DEL ARTE

La Tabla **??** resume cuatro trabajos que usan esta base de datos.

Anguita *et al.* (2013) [2] presentaron la base de datos junto con un modelo de referencia: una máquina de vectores de soporte (SVM) multiclase, con estrategia uno contra todos y núcleo gaussiano, entrenada sobre las 561 características. Seleccionaron los hiperparámetros con validación cruzada de 10 particiones y evaluaron en la partición de prueba (2 947 ventanas). Obtuvieron una exactitud global del 96 %. Por clase, la sensibilidad (*recall*) fue más baja para *sentado* (88 %), que se confunde sobre todo con *de pie*. Las clases dinámicas superaron el 96 % y *acostado* alcanzó el 100 %.

Ronao y Cho (2016) [3] propusieron una red neuronal convolucional (*convnet*) que aprende las características directamente de las señales inerciales, en lugar de usar las 561 calculadas a mano. Analizaron el efecto de la profundidad de la red, el tamaño del filtro y el tamaño del *pooling*. En el conjunto de prueba obtuvieron una exactitud de 94.79 % con las señales crudas y de 95.75 % al añadir características de la transformada rápida de Fourier. Según los autores, la red clasificó casi perfectamente las actividades en movimiento y superó a otras técnicas de minería de datos.

Xu *et al.* (2019) [4] propusieron CELearning, un modelo de ensamble en cascada. En cada nivel, cuatro clasificadores (XGBoost, *random forest*, *extra trees* y regresión *softmax*) generan probabilidades de clase que se concatenan con las entradas del nivel siguiente. Usaron la partición oficial por sujetos (7 352/2 947), validación cruzada de k particiones dentro de cada nivel y 10 ejecuciones. Reportaron la exactitud media y su desviación estándar, además de la precisión y la sensibilidad por clase. Con las 561 características obtuvieron una exactitud media de 96.67 % (± 0.11) y una máxima de 96.88 %; con características de la FFT, una media de 95.82 %. Individualmente, sus clasificadores base alcanzaron entre 90.87 % (XGBoost) y 95.89 % (*softmax*) con las 561 características.

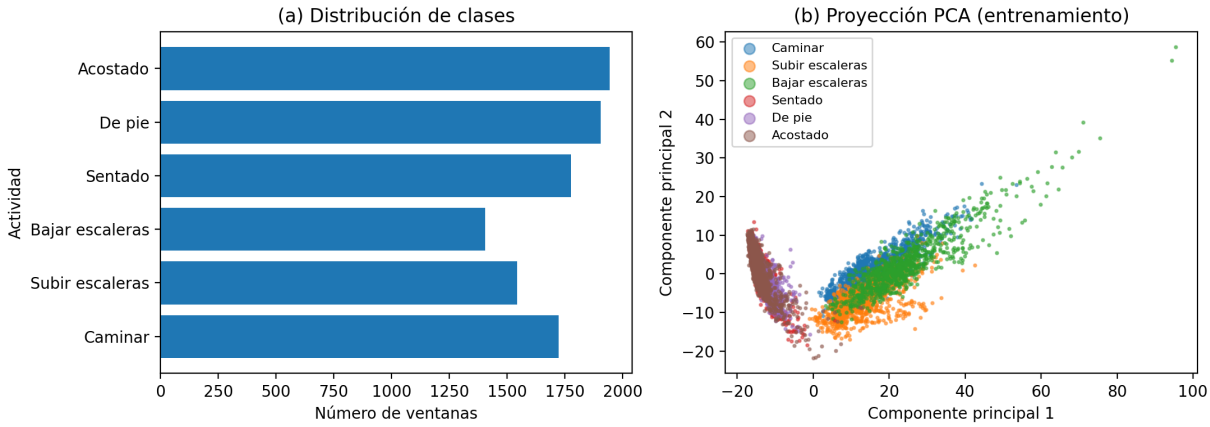


Figura 1. Análisis exploratorio. (a) Número de ventanas por actividad en toda la base de datos. (b) Proyección de las ventanas de entrenamiento sobre sus dos primeras componentes principales (características estandarizadas), coloreadas por actividad.

Pang *et al.* (2022) [5] propusieron el modelo SDFL, que apila tres módulos de aprendizaje de características discriminantes y clasifica con el vecino más cercano. Usaron una evaluación independiente del sujeto con 7 352 ventanas de entrenamiento y 2 947 de prueba. Reportaron exactitud, precisión, sensibilidad, F1, AUC y tasa de falsos positivos, y obtuvieron una exactitud de 96.27 % y un F1 de 0.963. En su tabla comparativa, el modelo en cascada de Xu *et al.* [4] con características manuales (96.88 %) quedó por encima de SDFL.

Métricas. Siendo TP_k, FP_k y FN_k los verdaderos positivos, falsos positivos y falsos negativos de la clase k, la precisión es $P_k = TP_k/(TP_k + FP_k)$, la sensibilidad es $R_k = TP_k/(TP_k + FN_k)$ y el F1 macro sobre K clases es

$$F1_{\text{macro}} = \frac{1}{K}\sum_{k=1}^{K}\frac{2\,P_k R_k}{P_k + R_k}. \tag{2}$$

El AUC que reportan Pang *et al.* es el área bajo la curva ROC, que relaciona la tasa de verdaderos positivos con la de falsos positivos al variar el umbral de decisión.

Análisis. Los trabajos coinciden en tres puntos que orientan nuestro proyecto. Primero, con la partición oficial por sujeto, la exactitud de los mejores modelos está entre 94 % y 97 %, de modo que las diferencias entre métodos son pequeñas y deben reportarse con intervalos de confianza. Segundo, una SVM sobre las características calculadas a mano es una referencia difícil de superar: las redes que aprenden de las señales crudas no la superan con claridad. Tercero, el error dominante es la confusión entre *sentado* y *de pie*. Por eso la matriz de confusión es más informativa que la exactitud global. Además, el trabajo de Xu *et al.* muestra que los ensambles de árboles y los modelos lineales ya rinden bien sobre las 561 características. Esto es coherente con los modelos que exige la guía del curso: un modelo paramétrico, uno no paramétrico, un ensamble de árboles, una red neuronal y una SVM.

III. Avances y próximos pasos

Hasta ahora definimos el problema como una clasificación supervisada multiclase con evaluación independiente del sujeto, analizamos la composición de la base de datos y revisamos trabajos previos que sitúan el desempeño de referencia entre 94 % y 97 % de exactitud. Este análisis es reproducible desde el notebook del repositorio del proyecto. En la siguiente etapa entrenaremos y compararemos los cinco modelos que exige la guía, ajustando sus hiperparámetros con validación agrupada por sujeto, y luego evaluaremos la reducción de dimensión con PCA y UMAP.

Referencias

[1] "Human Activity Recognition Using Smartphones," UCI Machine Learning Repository. [En línea]. Disponible: https://doi.org/10.24432/C54S4K

[2] D. Anguita, A. Ghio, L. Oneto, X. Parra y J. L. Reyes-Ortiz, "A public domain dataset for human activity recognition using smartphones," en *Proc. European Symposium on Artificial Neural Networks, Computational Intelligence and Machine Learning (ESANN)*, Brujas, Bélgica, 2013, pp. 437–442.

[3] C. A. Ronao y S.-B. Cho, "Human activity recognition with smartphone sensors using deep learning neural networks," *Expert Systems with Applications*, vol. 59, pp. 235–244, 2016, doi: 10.1016/j.eswa.2016.04.032.

[4] S. Xu, Q. Tang, L. Jin y Z. Pan, "A cascade ensemble learning model for human activity recognition with smartphones," *Sensors*, vol. 19, no. 10, art. 2307, 2019, doi: 10.3390/s19102307.

[5] Y. H. Pang, L. Y. Ping, G. F. Ling, O. S. Yin y K. W. How, "Stacked deep analytic model for human activity recognition on a UCI HAR database," *F1000Research*, vol. 10, art. 1046, 2022, doi: 10.12688/f1000research.73174.3.